EXPLORATORY DATA ANALYSIS

by Irwan Lazuardi Saldeni

14 September 2026

TABLE OF CONTENT

- Introduction
  - Project Overview
    - Main Project

INTRODUCTION



Irwan Lazuardi Saldeni
@dibimbing Bootcamp Data Analist

Education

Universitas Gadjah Mada
Electrical Engineering
Graduated at Mei 2025

Work Experience

Project Overhaul PLTU Sebalang
Instrument & Control Technician
June-August 2025

PROJECT OVERVIEW

- Implementation of the Web-Based Internet of Things in Building Management Systems Aspects of Fire Protection and HVAC

  Tools : Arduino, Thingspeak
- Employee Performance Evaluation: Dashboard performa pegawai dan recomendasi untuk meningkatkan performa

  Tools : MS. Excel
- Pre Processing Project: Project cleaning data dan mendeteksi masalah selama proses cleaning

  tools : Jupyter Notebook (Python)

MAIN PROJECT

- Problem Statement
  - Data Understanding
    - Data Preparation
      - Visualization
        - Recommendation

PROBLEM STATEMENT

- Hukum penawaran dan permintaan

Dalam hukum penawaran dan permintaan, harga bisa terbentuk dari interaksi antara penawaran dan permintaan. Pada marketplace, masing masing produk memiliki variasi harga, jumlah produk yang tersedia, serta jumlah produk yang telah terjual yang berbeda-beda. Perbedaan tersebut dapat mencerminkan karakteristik penawaran dan permintaan pada masing-masing produk. Oleh karena itu, Exploratory Data Analysis (EDA) dilakukan untuk melihat pola harga, ketersediaan produk, dan jumlah produk terjual serta hubungan berdasarkan brand dan jenis produk.

Analisis ini bertujuan untuk memperoleh gambaran mengenai bagaimana tingkat harga dan ketersediaan produk berkaitan dengan tingkat penjualan serta mengidentifikasi karakteristik produk yang menunjukkan permintaan relatif tinggi atau rendah.

DATA UNDERSTANDING

- Data Set : ebay_womens_perfume.csv
- Row : 1000
- Missing Value : brand (0.1%), type (0.2%), available (13.1%), availableText (0.8%), sold (1.6%), lastUpdate (7.3%)
- Duplicated : 0.1 %

Kolom	Penjelasan
brand	Nama merek parfum yang tercantum pada listing eBay
title	Judul lengkap listing produk di eBay. Biasanya berisi nama parfum, ukuran, konsentrasi, kondisi produk, dan keterangan tambahan dari seller.
type	Jenis atau konsentrasi fragrance
price	Harga produk dalam bentuk numerik, tanpa simbol mata uang
priceWithCurrency	Harga produk dalam format teks lengkap beserta mata uang dan kadang keterangan tambahan.
available	Jumlah stok yang tercatat tersedia pada listing.
availableText	Teks asli dari eBay yang menjelaskan kondisi stok dan terkadang jumlah produk terjual.
sold	Jumlah unit yang tercatat sudah terjual pada listing tersebut.
lastUpdated	Waktu terakhir informasi listing diperbarui atau diambil, lengkap dengan tanggal, jam
itemLocation	Lokasi barang atau seller yang tercantum pada listing

INCONSISTEN DATA

```
df_raw['brand'].value_counts().count()
```

```
np.int64(247)
```

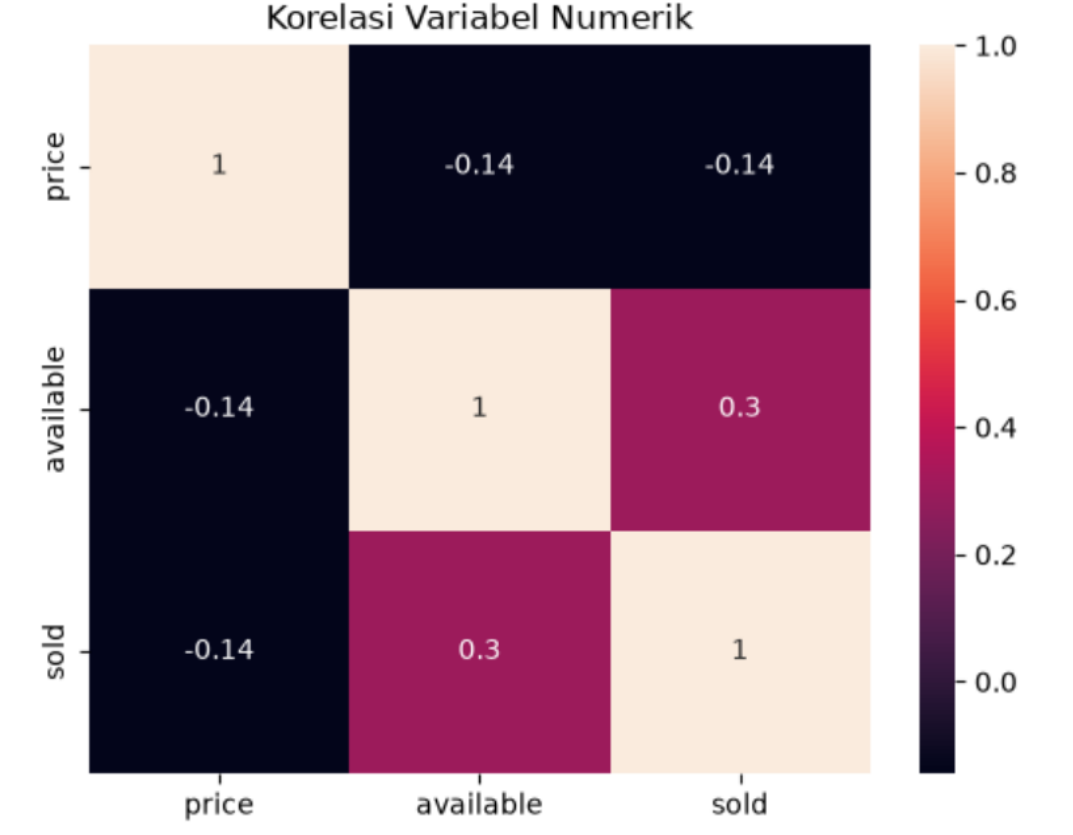
```
df_raw['type'].value_counts().count()
```

```
np.int64(71)
```

```
AS  SHOWN                                  1
AS SHOW                                    3
AS SHOWN                                  15
```

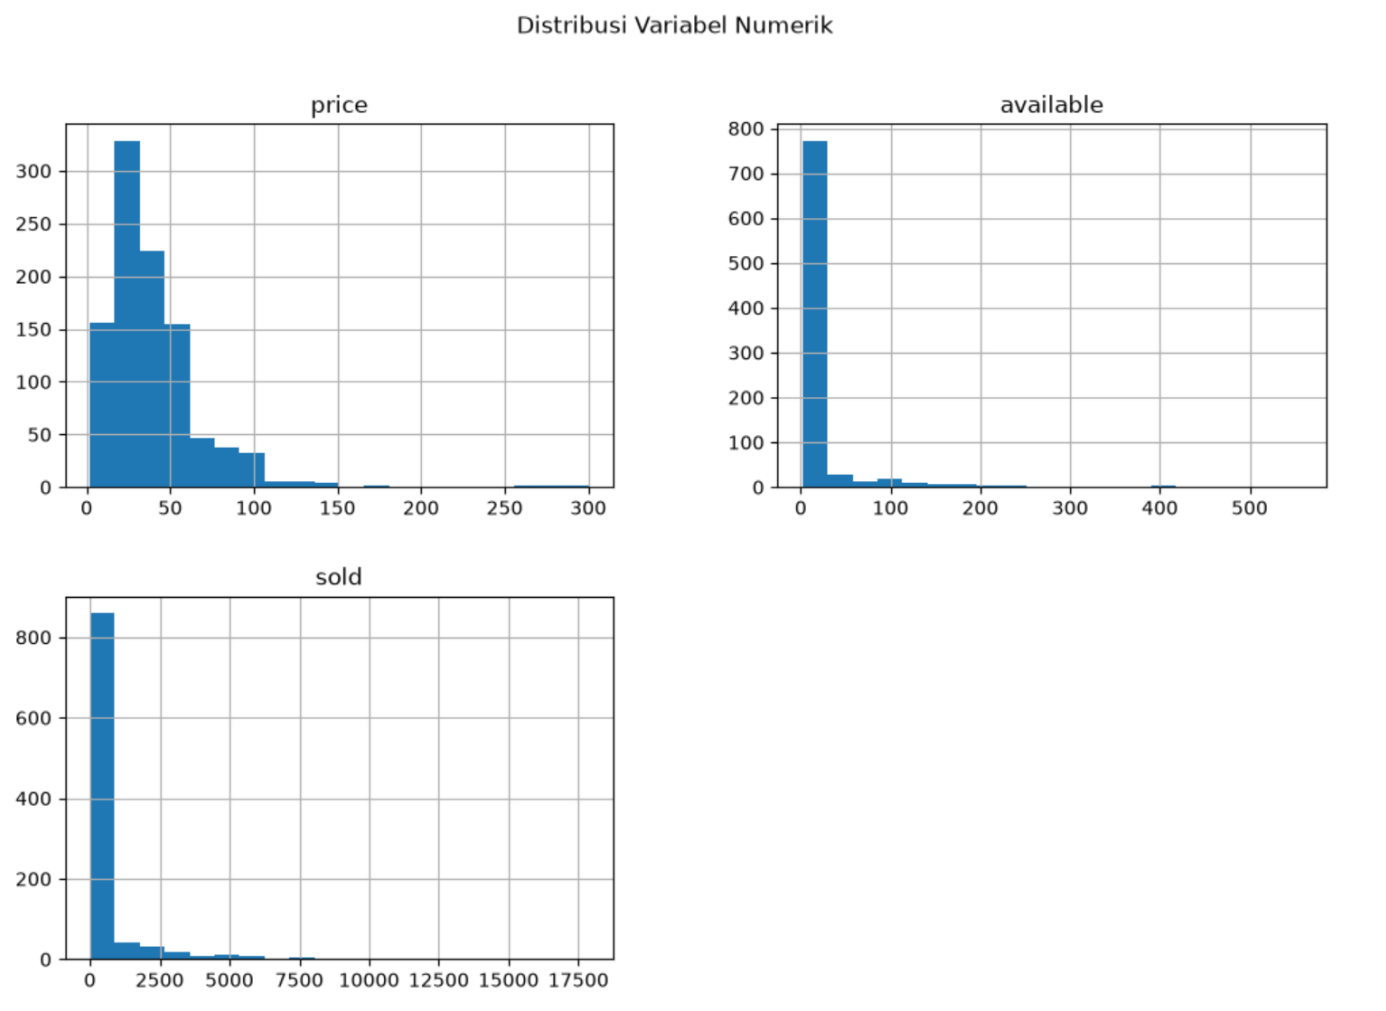
```
Eau De Parfum                                                16
Eau De Parfum 2 Pcs Set                                       1
Eau De Parfum 3 Pcs Set                                       1
Eau De Parfum Spray (Unisex Tester) 3.4 oz                    1
Eau De Parfum Supreme                                         1
```

KORELASI VARIABLE NUMERIK



Dari korelasi sebelum cleaning, dapat dilihat bahwa anatar variable numerik memiliki korelasi yang sangat kecil. Availabel dan sold memiliki korelasi positif dan sold/available memiliki korelasi negatif dengan price

DISTRIBUSI



Ketiga variable numerik memiliki distribusi yang miring ke kanan. Hal ini disebabkan adanya nilai ekstrem yang menarik nilai mean ke arah kanan.

DATA PREPARATION

- Duplicates
- Missing Value
- Correct Inconsistencies
- Unnecessary columns
- Standardize Format
- Data types
- Outliers

DUPLICATES

[8]:
```
df_raw[df_raw.duplicated(keep=False)]
```

[8]:

	brand	title	type	price	priceWithCurrency	available	availableText	sold	lastUpdated	itemLocation
344	FLOWER	12 Piece Woman's Perfume Lot: Assorted scents ...	Perfume	48.0	US $48.00	4.0	4 available / 1 sold	1.0	NaN	Webster, Florida, United States
662	FLOWER	12 Piece Woman's Perfume Lot: Assorted scents ...	Perfume	48.0	US $48.00	4.0	4 available / 1 sold	1.0	NaN	Webster, Florida, United States

[57]:
```
duplikat = df_raw.duplicated().sum() / len(df_raw) * 100   # % Duplikat
print ("Duplikat(%):",duplikat)
```

```
Duplikat(%): 0.1
```

Hapus duplikat

[58]:
```
df = df_raw.copy()
df = df.drop_duplicates()        #Data Frame baru untuk di cleaning
df[df.duplicated(keep=False)]
```

[58]:

	brand	title	type	price	priceWithCurrency	available	availableText	sold	lastUpdated	itemLocation

Hanya ada satu baris duplikat, untuk penanganannya adalah dengan dihapus

MISSING VALUE (AVAILABLETEXT)

Memisahkan missing value "availableText" menjadi dataframe baru

[24]:
```
df_discontinue = df[df["availableText"].isna()].copy()
df = df[df["availableText"].notna()].copy()
df_discontinue
```

[24]:

	brand	title	type	price	priceWithCurrency	available	availableText	sold	lastUpdated	itemLocation	price_c_clean
121	Ellis Brooklyn	NWB Ellis Brooklyn Miami Nectar Eau de Parfum ...	Eau de Parfum	33.00	US $33.00	NaN	NaN	NaN	NaN	Cranford, New Jersey, United States	33.00
602	Giardini Di Toscana	Bianco Latte EDP by Giardini Di Toscana 100 Ml...	Parfum	140.00	US $140.00	NaN	NaN	NaN	NaN	Houston, Texas, United States	140.00
732	Chanel	CHANEL Les Eaux De Chanel Paris Eau De Toilett...	Eau de Toilette	24.00	US $24.00	NaN	NaN	NaN	NaN	Los Angeles, California, United States	24.00
827	Ellis Brooklyn	NWB Ellis Brooklyn Biography Fragrance Discove...	Gift Set	17.00	US $17.00	NaN	NaN	NaN	NaN	Edison, New Jersey, United States	17.00
839	Lomani	SPICE ADDICT PRIVATE COLLECTION BY LOMANI EDP ...	Eau de Parfum	84.00	US $84.00	NaN	NaN	NaN	NaN	Hialeah, Florida, United States	84.00
880	Burberry	Burberry Goddess EDP Eau De Parfum Spray 3.3 o...	Eau de Parfum	95.00	US $95.00	NaN	NaN	NaN	NaN	West Hollywood, California, United States	95.00
927	Snif	Snif : Sweet Ash .07 FL. OZ. - Juniper, Fir Ba...	Parfum	14.95	US $14.95	NaN	NaN	NaN	NaN	Philadelphia, Pennsylvania, United States	14.95
983	Burberry	Burberry Her ELIXIR DE PARFUM EDP Intense-Delu...	Eau de Parfum	13.00	US $13.00	NaN	NaN	NaN	NaN	Chino, California, United States	13.00

"availableText" berisi informasi tentang available dan sold. Missing value pada kolom ini bisa menjadi indikasi bahwa produk-produk tersebut sudah tidak dijual lagi (discontinue). Sehingga untuk penanganan missing value kolom "availableText" Adalah dengan memisahkan dari data frame utama

DATA TYPES

```
[34]: df.info()
```

```
<class 'pandas.DataFrame'>
Index: 991 entries, 0 to 999
Data columns (total 13 columns):
 #   Column             Non-Null Count  Dtype
---  ------             --------------  -----
 0   brand              991 non-null    str
 1   title              991 non-null    str
 2   type               991 non-null    str
 3   price              991 non-null    float64
 4   priceWithCurrency  991 non-null    str
 5   available          991 non-null    float64
 6   availableText      991 non-null    str
 7   sold               991 non-null    float64
 8   lastUpdated        927 non-null    datetime64[us]
 9   itemLocation       991 non-null    str
 10  price_c_clean      991 non-null    float64
 11  Date               927 non-null    object
 12  Time               927 non-null    object
dtypes: datetime64[us](1), float64(4), object(2), str(6)
memory usage: 298.8+ KB
```

Memperbaiki tipe data

```
[35]: df[["available","sold"]] = df[["available","sold"]].astype(int)
df["Date"] = pd.to_datetime(df["Date"])
df.info()
```

```
<class 'pandas.DataFrame'>
Index: 991 entries, 0 to 999
Data columns (total 13 columns):
 #   Column             Non-Null Count  Dtype
---  ------             --------------  -----
 0   brand              991 non-null    str
 1   title              991 non-null    str
 2   type               991 non-null    str
 3   price              991 non-null    float64
 4   priceWithCurrency  991 non-null    str
 5   available          991 non-null    int64
 6   availableText      991 non-null    str
 7   sold               991 non-null    int64
 8   lastUpdated        927 non-null    datetime64[us]
 9   itemLocation       991 non-null    str
 10  price_c_clean      991 non-null    float64
 11  Date               927 non-null    datetime64[s]
 12  Time               927 non-null    object
dtypes: datetime64[s](1), datetime64[us](1), float64(2), int64(2), object(1), str(6)
memory usage: 298.8+ KB
```

OUTLIERS (TYPE)

```
[38]: df["type"].value_counts()
```

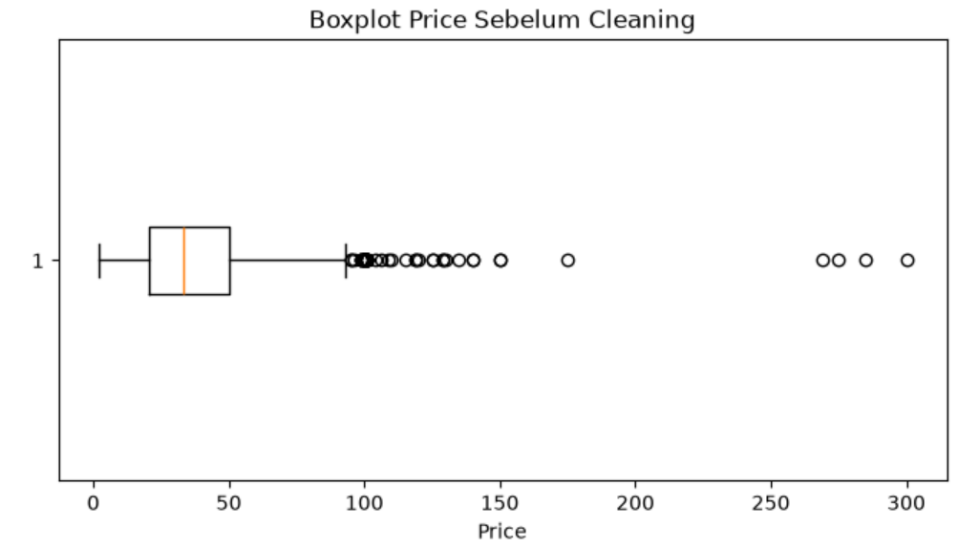
```
[38]: type
Eau de Parfum                                   615
Eau de Toilette                                 200
Parfum                                           63
Eau de Cologne                                   42
Fragrance Mist                                   16
fragrances                                       14
Body Lotion                                       8
Body Spray                                        6
Gift Set                                          5
Perfume Oil                                       5
Deodorant                                         2
does not apply                                    2
~ body firm advanced body repair treatment ~      1
3 pc                                              1
hair perfume                                      1
cream                                             1
shimmer                                           1
parfum, lotion, gloss and blush                   1
bath oil                                          1
asst                                              1
beauty                                            1
shimmering body oil                               1
body powder                                       1
solid perfume stick                               1
pink sugar                                        1
Name: count, dtype: int64
```

```
type_counts = df["type"].value_counts()
df["type"] = df["type"].apply(
    lambda x: x if type_counts[x] > 10 else "Others")

df["type"].value_counts()
```

```
type
Eau de Parfum      615
Eau de Toilette    200
Parfum              63
Eau de Cologne      42
Others              41
Fragrance Mist      16
fragrances          14
Name: count, dtype: int64
```

OUTLIERS (PRICE)

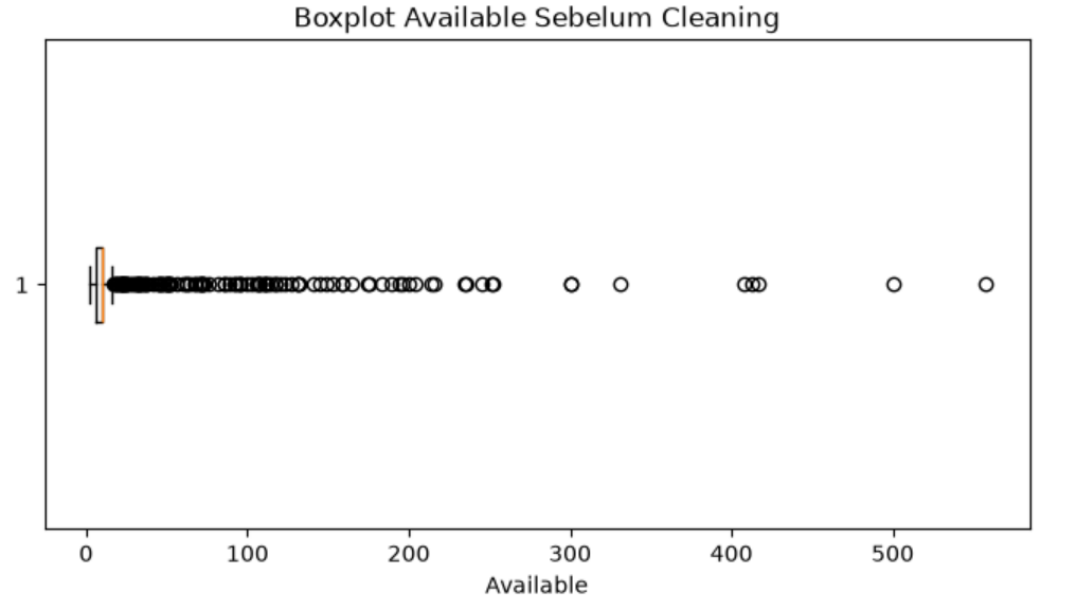



```
Q1: 20.75
Q3: 49.99
IQR: 29.240000000000002
Lower Bound: -23.11
Upper Bound: 93.85

[40]: np.int64(50)
```

Karna sangat mungkin jumlah stok bernilai besar, maka untuk nilai outlier “price” tidak dilakukan penanganan (dibiarkan)

OUTLIERS (AVAILABLE)

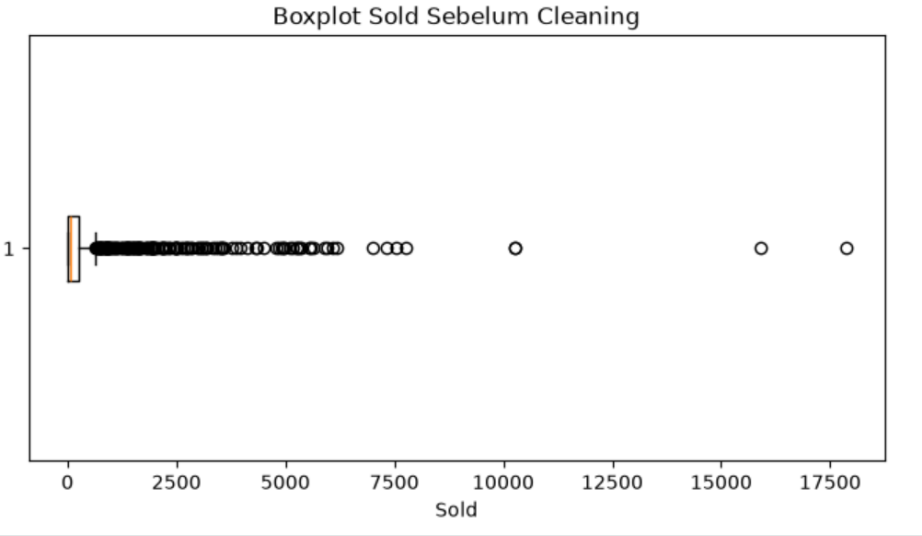



```
Q1: 5.0
Q3: 10.0
IQR: 5.0
Lower Bound: -2.5
Upper Bound: 17.5

[41]: np.int64(120)
```

Karna sangat mungkin jumlah stok bernilai besar, maka untuk nilai outlier “available” tidak dilakukan penanganan (dibiarkan)

OUTLIERS (SOLD)




```
Q1: 15.0
Q3: 258.0
IQR: 243.0
Lower Bound: -349.5
Upper Bound: 622.5

[42]: np.int64(148)
```

Karna sangat mungkin jumlah terjual bernilai besar, maka untuk nilai outlier “sold” tidak dilakukan penanganan (dibiarkan)

ENCODING

```
[70]: from sklearn.preprocessing import LabelEncoder
      df["type_e"]=LabelEncoder().fit_transform(df["type"])
      df[["type","type_e"]]
```

[70]:

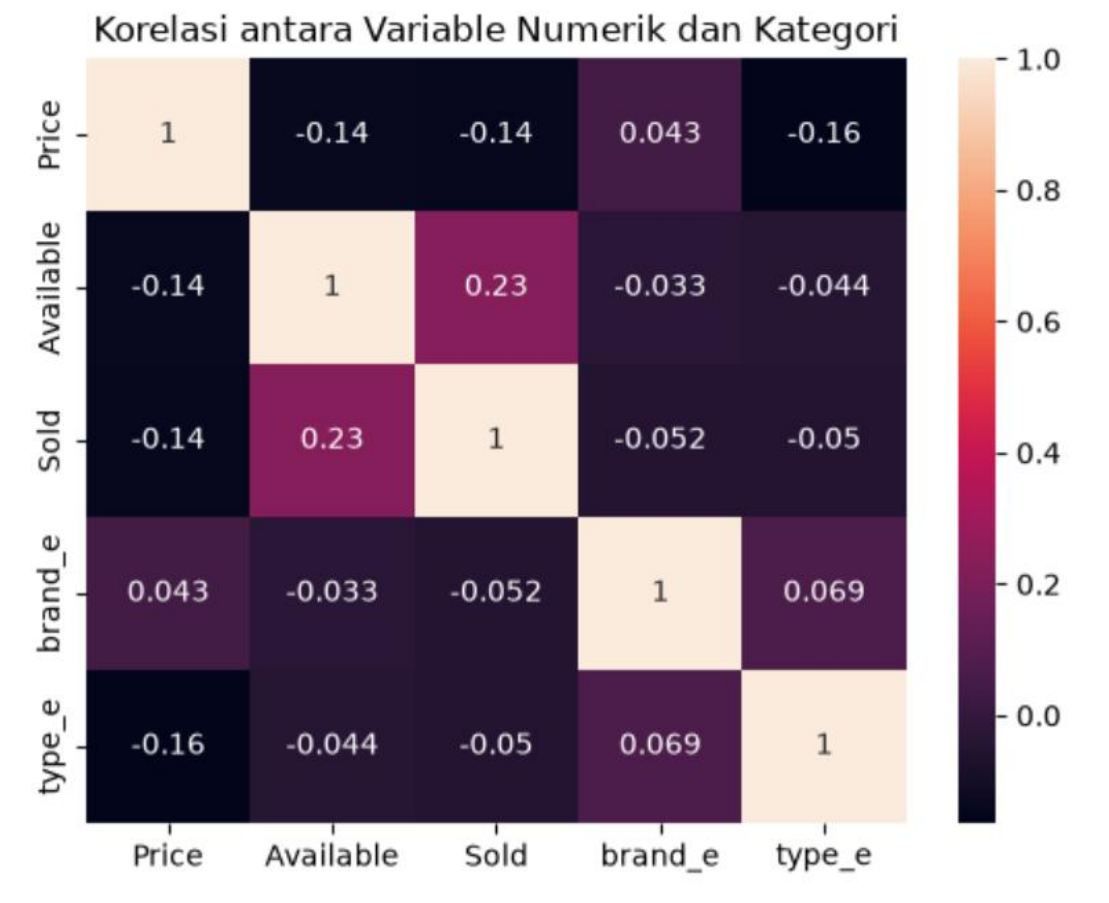
	type	type_e
0	Eau de Parfum	1
1	Eau de Parfum	1
2	Eau de Parfum	1
3	Eau de Parfum	1
4	Eau de Parfum	1
5	Eau de Parfum	1
6	Eau de Parfum	1
7	Eau de Toilette	2
8	Eau de Toilette	2

brand

```
[71]: df["brand_e"]=LabelEncoder().fit_transform(df["brand"])
      df[["brand","brand_e"]]
```

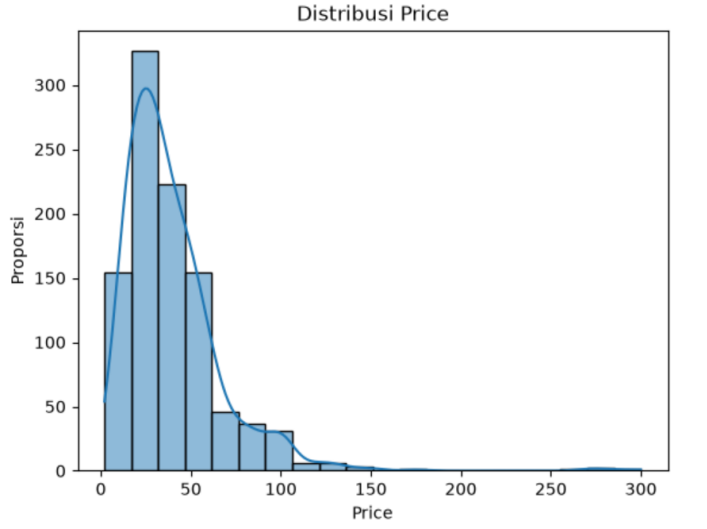
2	Prada	163
3	As Show	18
4	Khadlaj	113
5	Viktor & Rolf	204
6	As Show	18
7	Versace	201
8	Versace	201
9	Lattafa	120
10	Yves Saint Laurent	209
11	Gucci	85

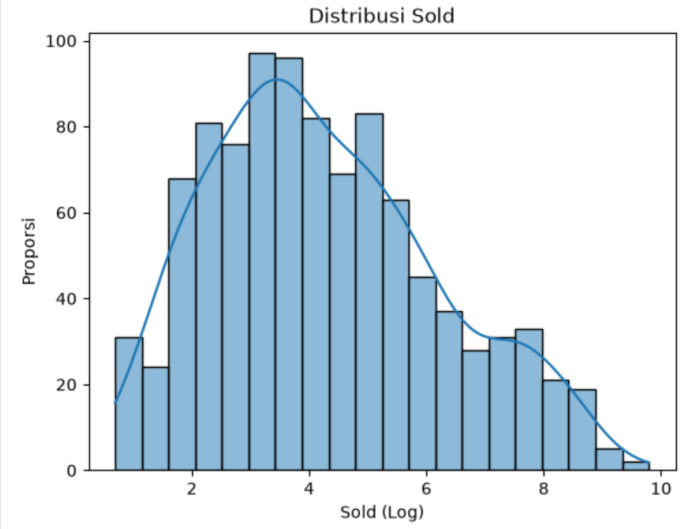
VISUALIZATION

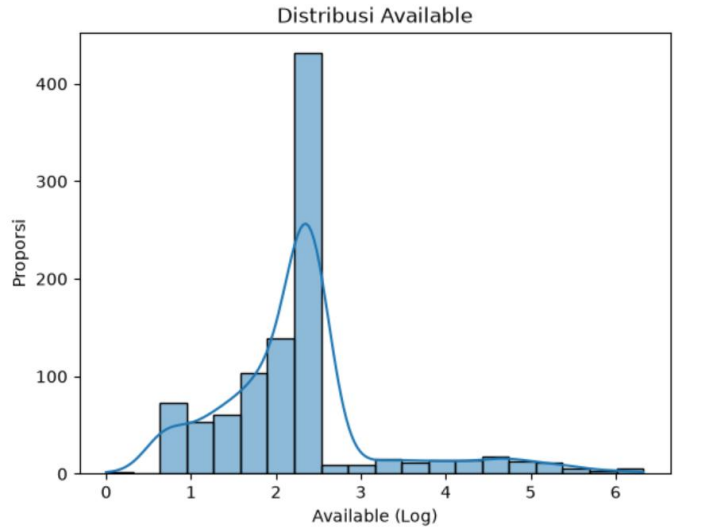


Setelah melakukan cleaning dan encoding, korelasi antara variable cenderung kecil. Ini meindikasi bahwa banyak faktor-faktor lain yang mempengaruhi Tingkat penjualan suatu parfum.

UNIVARIAT

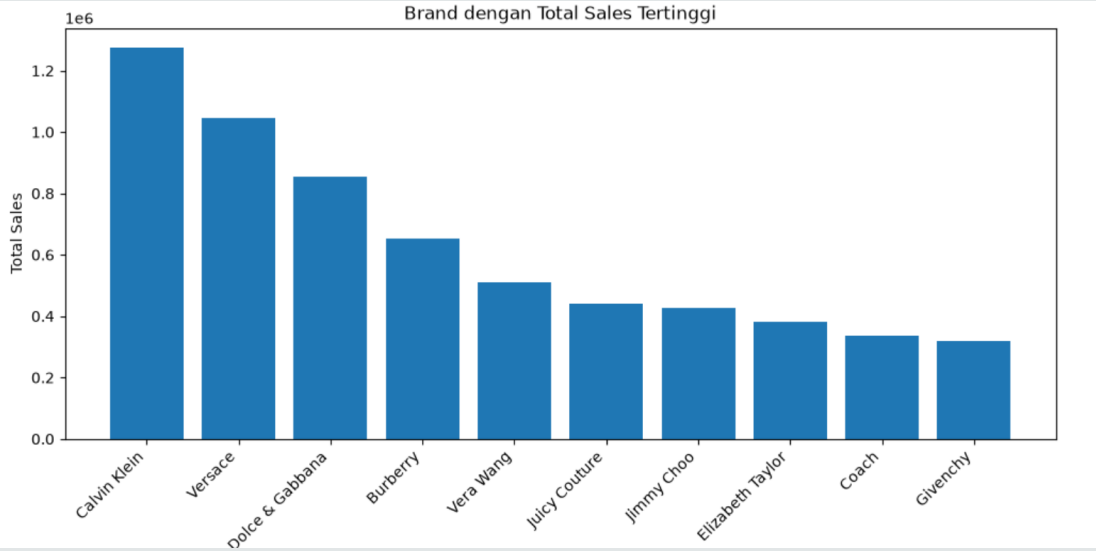


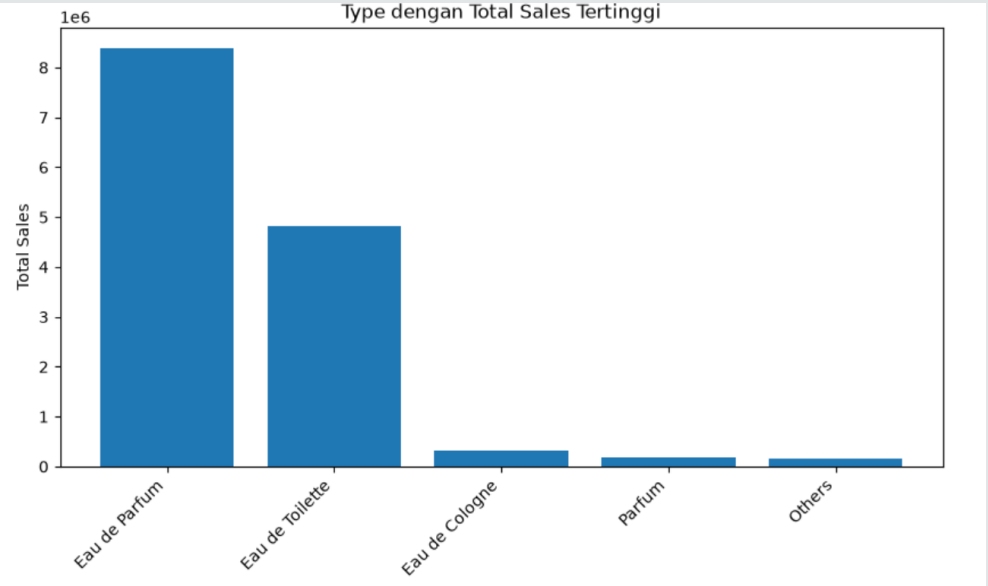




Setelah dilakukan cleaning, bentuk distrubusi tetap miring kekanan. Setelah dilakukan transformasi log, distribusi tetap miring ke kanan.

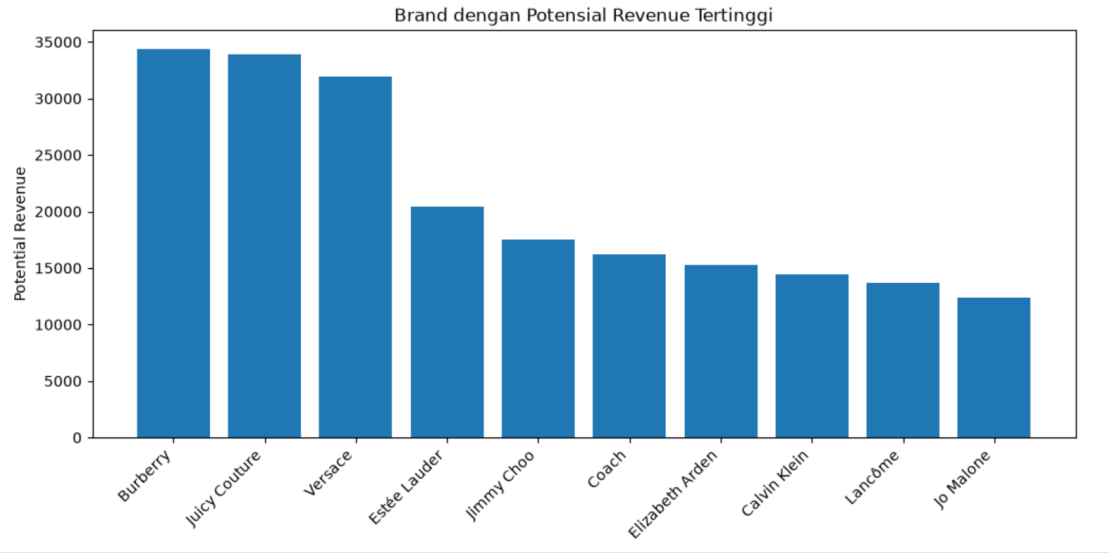
BIVARIAT (TOTAL SALES)

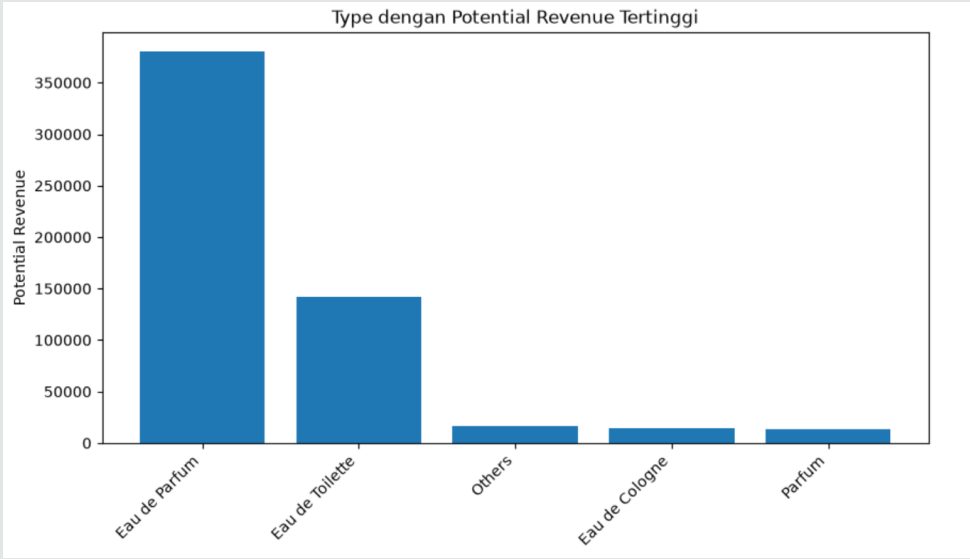




Brand Gloria Vanderbilt menjadi brand dengan total sales terbanyak. Sementara type Eau de Parfum menjadi type parfum dengan total sales terbanyak.

BIVARIAT (POTENTIAL REVENUE)

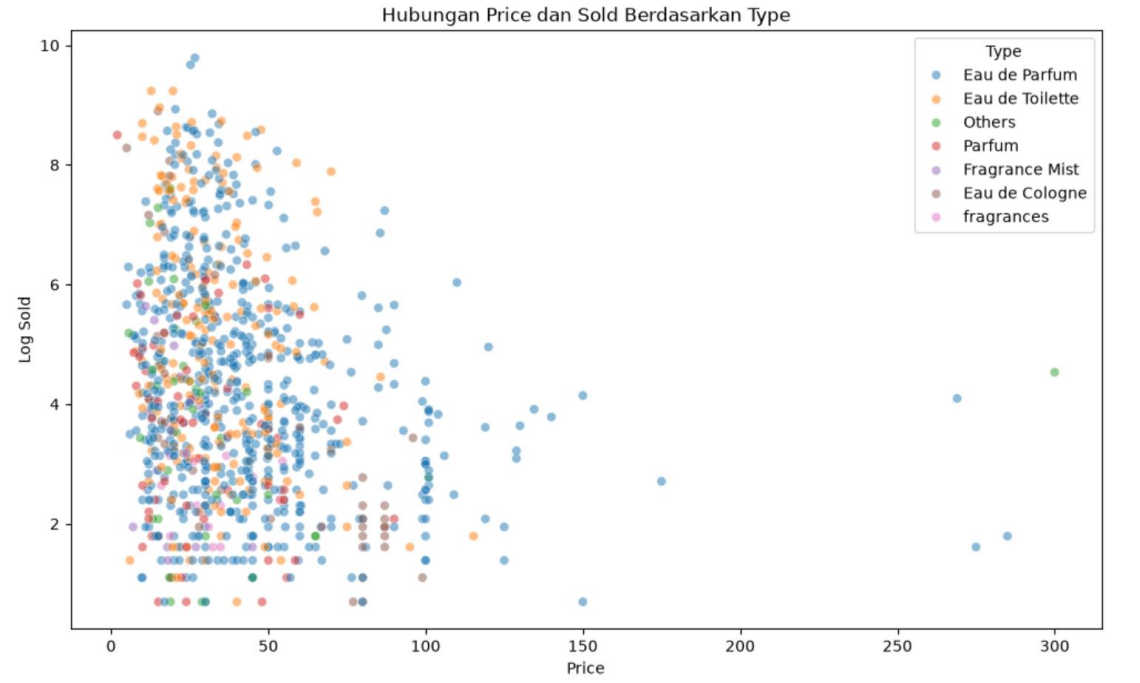




Brand Burberry menjadi brand dengan potensial revenue tertinggi. Sementara type Eau de Parfum menjadi type parfum dengan potensial revenue tertinggi. Perusahaan bisa menfokuskan strategi marketing untuk brand atau type parfum tersebut untuk memaksimalkan pendapatan

MULTIVARIAT





Dengan membandingkan price dengan sold berdasarkan brand dan type, pola pergerakan price dan sold cenderung tidak terlihat. Hal ini dikarenakan nilai korelasi yang cenderung rendah.

CONCLUSION

- Perusahaan perlu memvalidasi beberapa “title” parfum yang terindikasi discontinue kepada pihak brand.
- Antar variable memiliki korelasi yang rendah sehingga sulit menentukan pola yang dapat meningkatkan penjualan
- Brand Gloria Vanderbilt atau type parfum Eau de Parfum menjadi produk dengan total sales terbanyak.
- Perusahaan bisa memanfaatkan beberapa brand atau type parfum yang memiliki potensi revenue tinggi untuk memaksimalkan pendapatan.